# DM 2024 Lab2 report

# **Data preprocessing**

• 讀取data identification資料,將資料切分成train與test資料

```
input_path = '/kaggle/input/dm-2024-isa-5810-lab-2-homewor
k'

# Read train and test identification data
import pandas as pd
data_ids = pd.read_csv(f'{input_path}/data_identification.
csv')
print('data_identification')
print(data_ids.head())

# Split the data into training and testing sets.
train_data_ids = data_ids[data_ids['identification'] == 't
rain'].drop(['identification'], axis=1)
test_data_ids = data_ids[data_ids['identification'] == 'te
st'].drop(['identification'], axis=1)
print('train')
print('train_data_ids.head())
```

• 讀取emotion.csv中情緒類別資訊

```
# read
emotion_labels = pd.read_csv(f'{input_path}/emotion.csv')
emotion_labels.head()
```

• 讀取tweets\_DM.json資料,並且將其格式處理成表格模式,將tweets的文本資料與 訓練資料和測試資料合併,並將emotion的label放入訓練資料的欄位

```
tweets_df = pd.read_json(f'{input_path}/tweets_DM.json', l
ines=True)
```

```
print(tweets_df.head())

source_df = pd.json_normalize(tweets_df['_source'])

tweets_df = pd.concat([tweets_df.drop(columns=['_source']), source_df], axis=1)

print(tweets_df.head())

train_data = pd.merge(train_data_ids, emotion_labels, on ='tweet_id', how='inner')

train_data = pd.merge(train_data, tweets_df, left_on='tweet_id', right_on='tweet_id', how='inner')

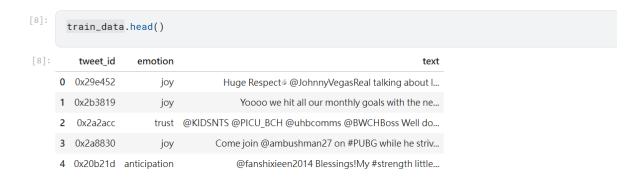
train_data.head()

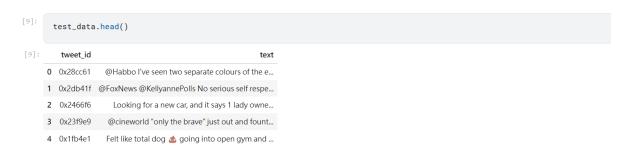
test_data = pd.merge(test_data_ids, tweets_df, left_on='tweet_id', right_on='tweet_id', how='inner')

test_data.head()
```

### • 去除資料中不必要的欄位,並重新命名欄位名稱

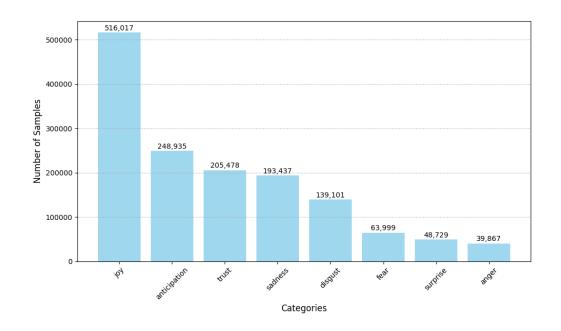
```
# drop useless column
drop_columns = ['_score','_index','_crawldate','_type','tw
eet.hashtags','tweet.tweet_id']
train_data.drop(drop_columns,axis=1,inplace=True)
test_data.drop(drop_columns,axis=1,inplace=True)
# rename column name
train_data = train_data.rename(columns={"tweet.text": "tex
t"})
test_data = test_data.rename(columns={"tweet.text": "tex
t"})
```



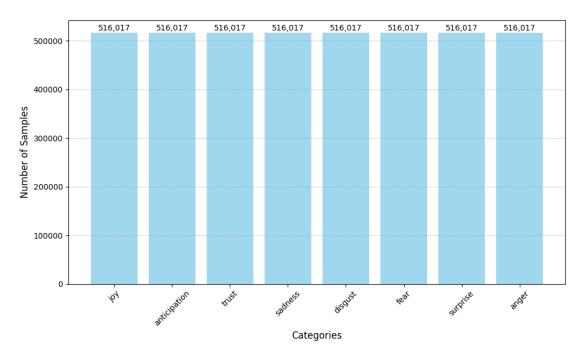


#### 資料類別分布的分析

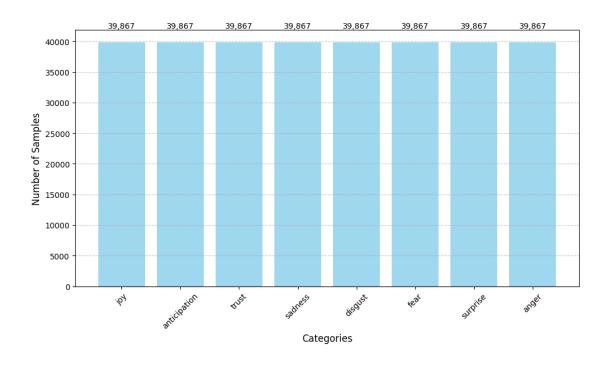
- 。 當資料內數量比例超過1:4時,建議在分析前將資料不平衡的問題納入考量 (https://ithelp.ithome.com.tw/m/articles/10294614)
- 。 原始訓練資料集中類別資料分布



#### 。 上採樣後的類別資料分布

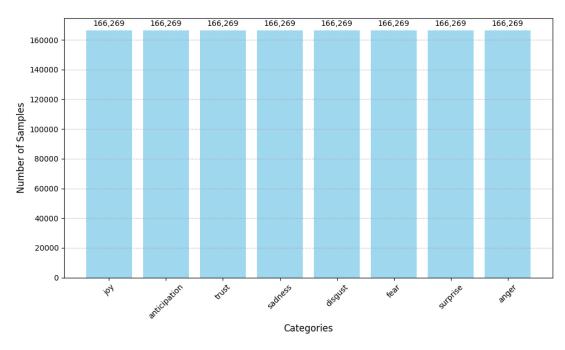


### 。 下採樣後的類別資料分布



### 。 中位數採樣後的類別資料分布

想法: 取得類別資料的中位數做為採樣目標數,少於中位數的類別進行上採樣,大於中位數的類別進行下採樣



#### • 資料缺失值的分析

。 未檢查出有缺失值資料

```
# check whether there is null data
train_data["text"].isna().sum()
```

• 將emotion的字串標籤轉換成整數型態的標籤,以利於後續模型訓練

```
# label encode the emotion data
from sklearn.preprocessing import LabelEncoder
labelencoder = LabelEncoder()
train_data['labels'] = labelencoder.fit_transform(train_data
```

#### • 前處理文本資料

- 。 tokenize方法
  - 方法1: 使用nltk中的TweetTokenizer對text進行tokenize
  - 方法2: 使用bertweet預設tokenizer,可以參考 https://github.com/VinAlResearch/BERTweet中的介紹
- 。 處理text資料

■ 我參考了<a href="https://github.com/VinAlResearch/BERTweet">https://github.com/VinAlResearch/BERTweet</a>中
<a href="https://github.com/VinAlResearch/BERTweet">TweetNormalizer</a> 的程式,他會對於一些hashtag標籤以及http url網址統一成一個可識別的token,並且會處理text中縮寫不一致的問題。

```
from transformers import AutoTokenizer
from nltk.tokenize import TweetTokenizer
model name = "vinai/bertweet-base"
# tokenize method 1: nltk TweetTokenizer
tokenizer = TweetTokenizer()
# tokenize method 2: bertweet default tokenizer
tokenizer = AutoTokenizer.from_pretrained(model_name)
def normalizeToken(token):
               lowercased token = token.lower()
               if token.startswith("@"):
                             return "@USER"
               elif lowercased_token.startswith("http") or lowercased_to
                             return "HTTPURL"
               elif len(token) == 1:
                             return demojize(token)
               else:
                             if token == "'":
                                            return "'"
                            elif token == "...":
                                            return "..."
                            else:
                                            return token
def normalizeTweet(tweet):
               tokens = tokenizer.tokenize(tweet.replace("'", "'").replace("'", "'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("'").replace("").replace("'").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("").replace("
               normTweet = " ".join([normalizeToken(token) for token in
               normTweet = (
                             normTweet.replace("cannot ", "can not ")
```

```
.replace("n't ", " n't ")
    .replace("n 't ", " n't ")
    .replace("ca n't", "can't")
    .replace("ai n't", "ain't")
normTweet = (
    normTweet.replace("'m ", " 'm ")
    .replace("'re ", " 're ")
    .replace("'s ", " 's ")
    .replace("'ll ", " 'll ")
    .replace("'d ", " 'd ")
    .replace("'ve ", " 've ")
)
normTweet = (
    normTweet.replace(" p . m .", " p.m.")
    .replace(" p . m ", " p.m ")
    .replace(" a . m .", " a.m.")
    .replace(" a . m ", " a.m ")
)
return " ".join(normTweet.split())
```

• 將資料打包成Dataset格式,以便後續模型訓練

```
class TweetDataset(Dataset):
    def __init__(self, tweets, labels=None):
        self.tweets = tweets
        self.labels = labels

def __len__(self):
        return len(self.tweets)

def __getitem__(self, idx):
        tweet = normalizeTweet(self.tweets[idx])
        encoding = tokenizer(tweet, padding="max_length",
```

```
truncation=True, max_length=128, return_tensors="pt")
        if self.labels is not None:
            return {
                "input ids": encoding["input ids"].squeeze
(),
                "attention_mask": encoding["attention_mas
k"].squeeze(),
                "labels": torch.tensor(self.labels[idx], d
type=torch.long),
        else:
            return {
                "input_ids": encoding["input_ids"].squeeze
(),
                "attention mask": encoding["attention mas
k"].squeeze(),
train_dataset = TweetDataset(train_split['text'], train_sp
lit['labels'])
eval_dataset = TweetDataset(eval_split['text'], eval_split
['labels'])
```

## Model

- 我使用hugging face中的Bertweet model作為pretrained model,並且使用訓練資料進行fine-tuning
  - 。 參考資料: <a href="https://huggingface.co/vinai/bertweet-base">https://huggingface.co/vinai/bertweet-base</a>
  - 。 其中BERTweet 是首個針對英語推文(Tweets)進行大規模預訓練的公開語言模型。BERTweet 是基於 RoBERTa 預訓練過程進行訓練的。用於預訓練BERTweet 的語料庫包含了 8.5 億條英語推文(約 160 億個詞元,大小約80GB),其中包括 8.45 億條從 2012 年 1 月到 2019 年 8 月期間流式獲取的推文,以及 500 萬條與 COVID-19 大流行相關的推文。

```
from transformers import AutoModel, AutoTokenizer, AutoModelF
orSequenceClassification, Trainer, TrainingArguments
#read pretrained bertweet model
model name = "vinai/bertweet-base"
model = AutoModelForSequenceClassification.from_pretrained(mo
del_name, num_labels=8)
# Train arguments setting
training_args = TrainingArguments(
    output_dir="./results",
    run_name="bert-finetuning",
    #eval_strategy="no",
    save_strategy="epoch",
    eval_strategy="epoch",
    learning_rate=2e-5,
    per_device_train_batch_size=32,
    num_train_epochs=1,
    weight_decay=0.01,
    logging_dir="./logs",
    report_to=[],
    fp16=True,
    #no_cuda=False,
)
# Define trainer
trainer = Trainer(
    model=model,
    args=training_args,
    train_dataset=train_dataset,
    eval_dataset=eval_dataset,
    compute_metrics=compute_metrics,
)
# bertweet model fine-tuning
trainer.train()
```

# save bertweet-finetuned model
model.save\_pretrained("./bertweet-finetuned")

# **Experiment Result**

## 實驗一: 使用nltk中的TweetTokenizer

Public score	Private score
0.53970	0.52692

### 實驗二: 使用bertweet-base model預設的tokenizer

Public score	Private score
0.57060	0.55577

### 實驗三: 處理類別資料不平衡問題

- 上採樣
  - 。 超時,無法執行
- 下採樣

Public score	Private score
0.49259	0.48050

• 中位數採樣

Public score	Private score
0.52621	0.51354